Tecnologia Em ADS

. Detectar Valores Discrepantes Outliers

Prof. Dr. Ricardo Luis Balieiro

Análise Exploratória de Dados - EDA

As principais etapas da EDA são:

01. Compreender o problema
02. Explorar o conjunto de dados
03. Tratar de valores ausentes
04. Remover registros duplicados
05. Detectar valores discrepantes - Outliers
06. Estudar as Distribuições de Características
07. Explorar as relações entre as variáveis
08. Preparar funcionalidades
09. Verificar o equilíbrio das classes
10. Dividir o conjunto de dados

O que é um Outlier?

- **Outlier** ➔ Uma observação que se afasta drasticamente do padrão geral dos dados. Pode surgir por erro de medição (ruído) ou variabilidade natural extrema.

- **Ruído ou erro de medição**
  Exemplo: erro de digitação de idade = 150 anos).

- **Variabilidade natural extrema**
  Exemplo: salário de um CEO na amostra de uma empresa).

Valores discrepantes contextuais

- A temperatura de 30°C no inverno é outlier?
  - Ceara – Rio Grande do Sul.

- O Salário de R$ 50.000,00 é outlier?
  - Colaboradores - CEO da empresa.

Outliers

Id	Categoria	Vendas	Preço	Pontuação	Perfil
1	A	-150.0	0.5	-99.0	Outliers Mínimos
2	B	150.0	48.0	70.0	Intervalo Normal
3	A	160.0	50.0	75.0	Intervalo Normal
4	C	155.0	52.0	72.0	Intervalo Normal
5	B	1200.0	650.0	950.0	Outliers Máximos

Identificação de Outliers

Os principais métodos de identificação do outliers são:

- Métodos Visuais
- Métodos Estatísticos
- Métodos baseados em aprendizado de máquina

Identificação Visual de Outliers

- **Análise Exploratória Visual** → Primeira linha de defesa antes de aplicar filtros matemáticos:
- **Boxplot (Diagrama de Caixa)** → Visualização de quartis e pontos atípicos:
  - Pontos fora dos "bigodes" (whiskers) → Candidatos a outliers.
- **Scatter Plot (Gráfico de Dispersão)** → Detecção em duas dimensões:
  - Identificação de pontos isolados da nuvem principal de dados.

Identificação Visual de Outliers

IQR OUTLIER DETECTION

Understanding, Detecting & Handling Outliers

Without Assuming Normal Distribution

THE 1.5 × IQR RULE

Lower Limit = Q1 − 1.5 × IQR

Upper Limit = Q3 + 1.5 × IQR

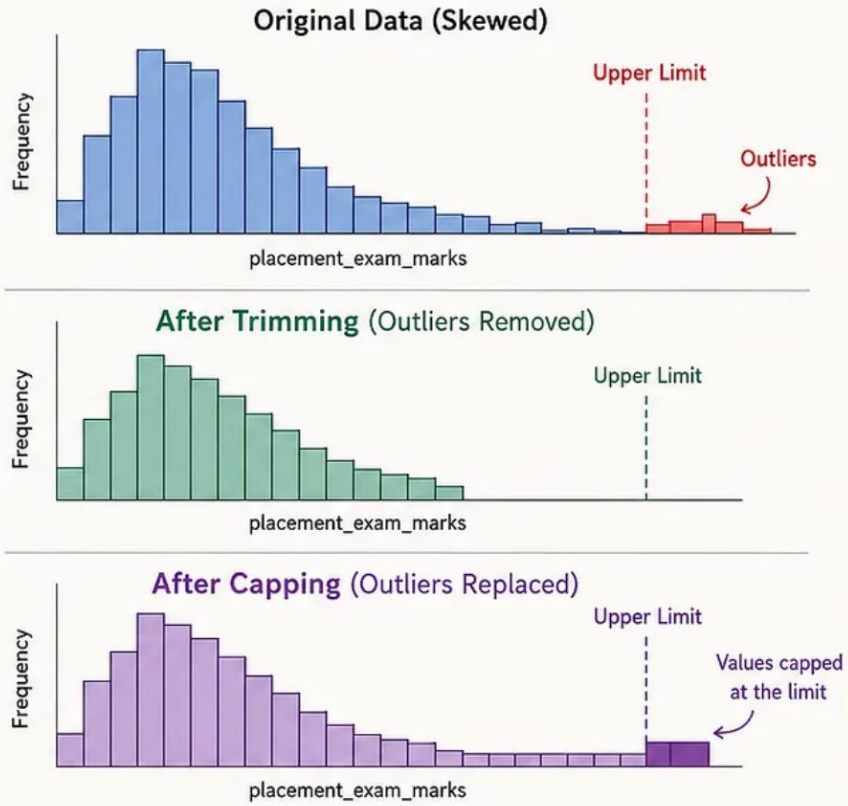
IQR = Q3 − Q1

- Robust to outliers
- Works well on skewed data
- Simple & effective for real-world data

BOX PLOT & IQR CONCEPT



HANDLING OUTLIERS: TRIMMING vs CAPPING



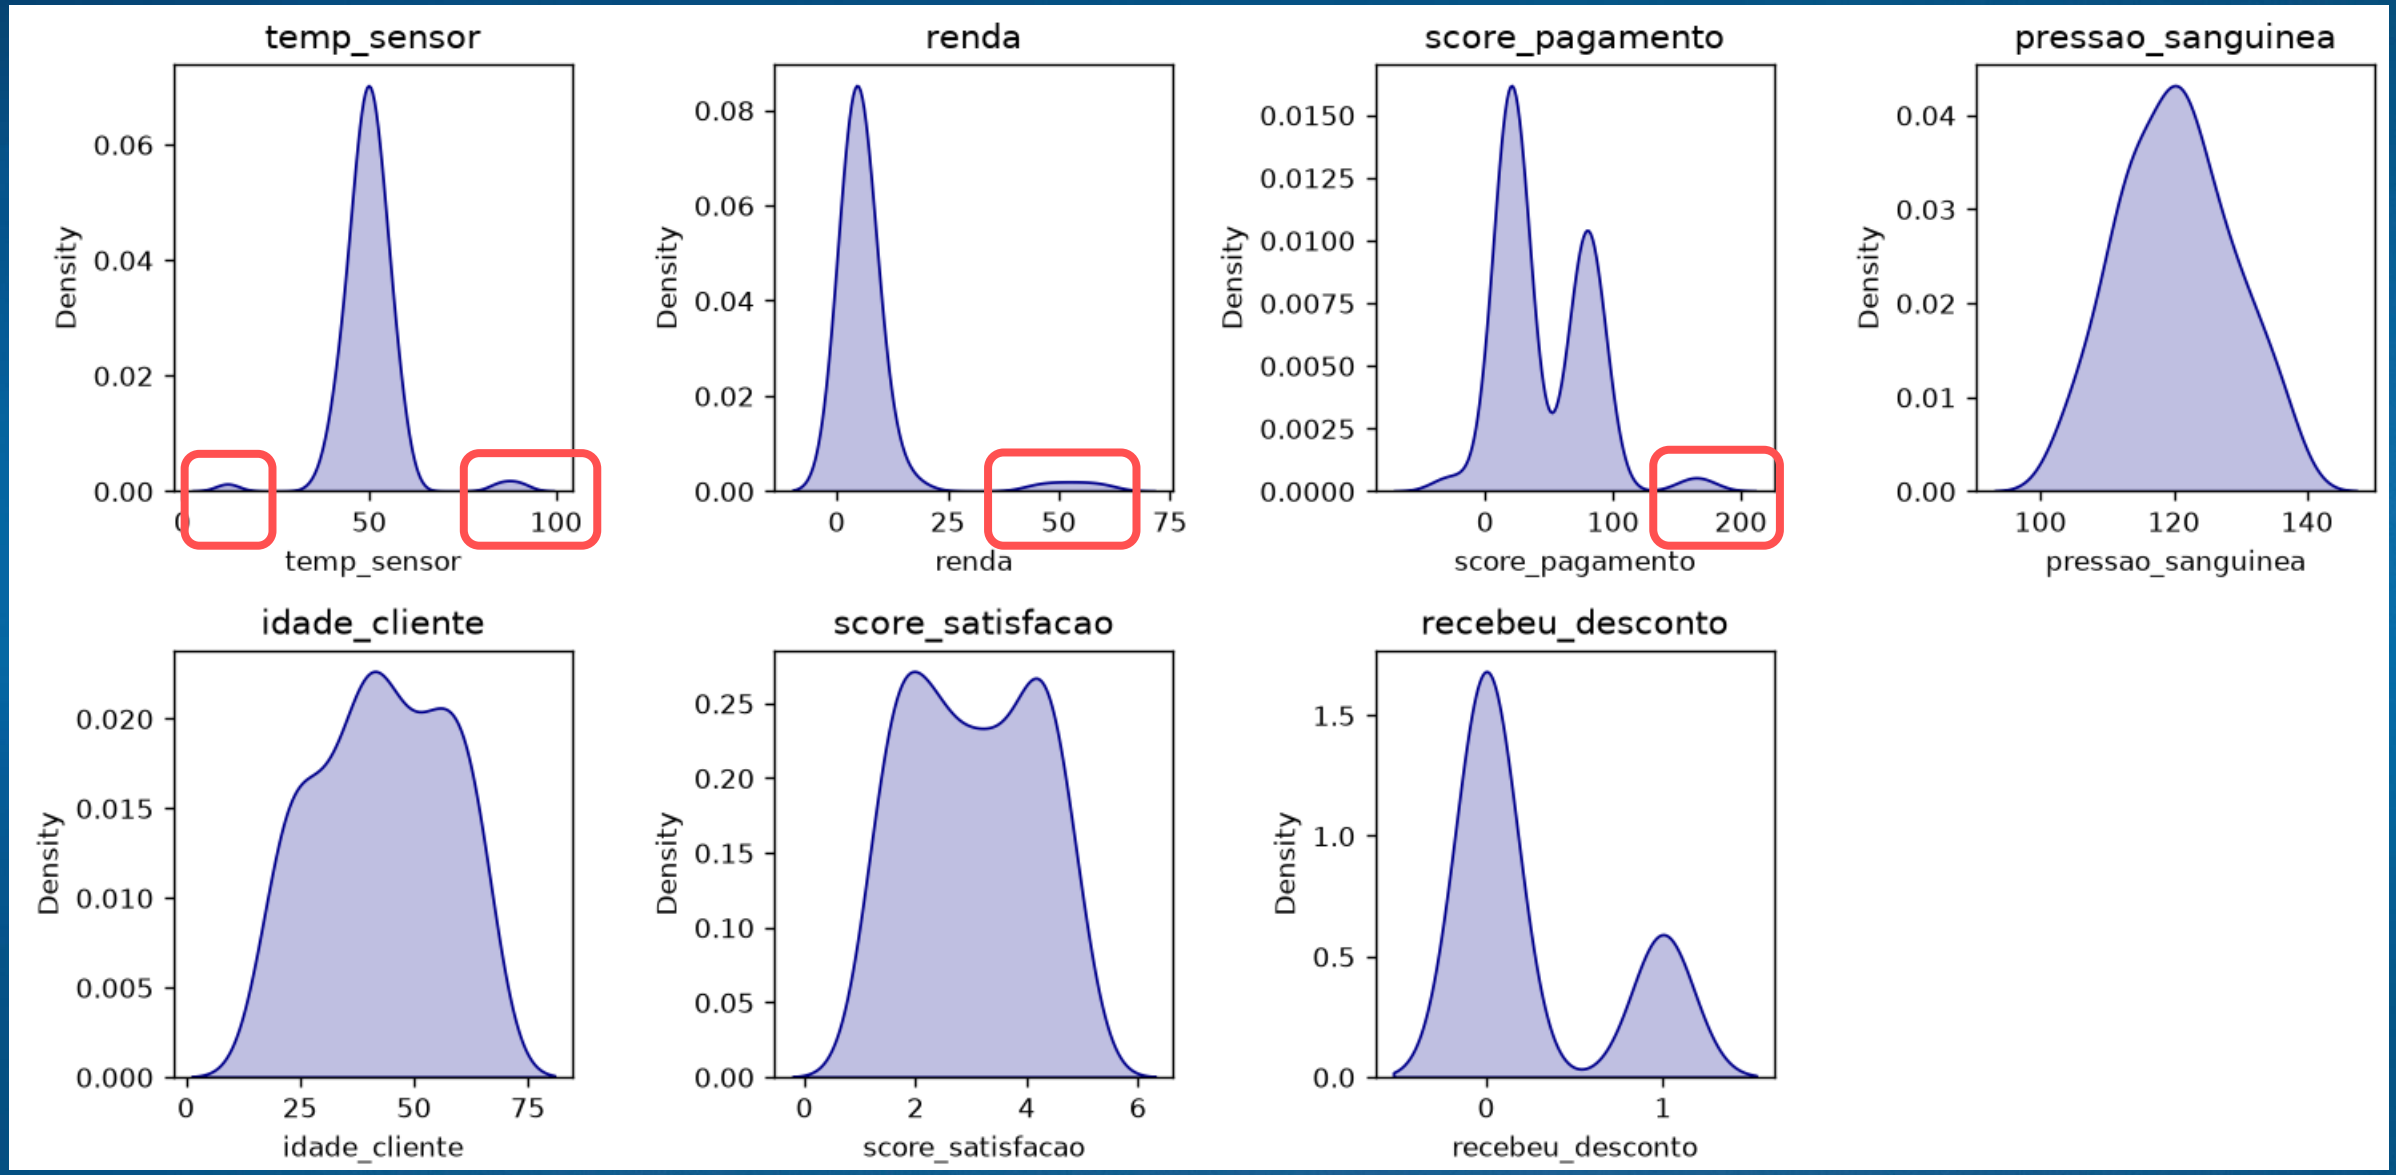
Use IQR when your data is skewed or contains extreme values.
Choose TRIMMING when outliers are errors. Choose CAPPING when outliers are genuine.

Técnicas para lidar com valores discrepantes

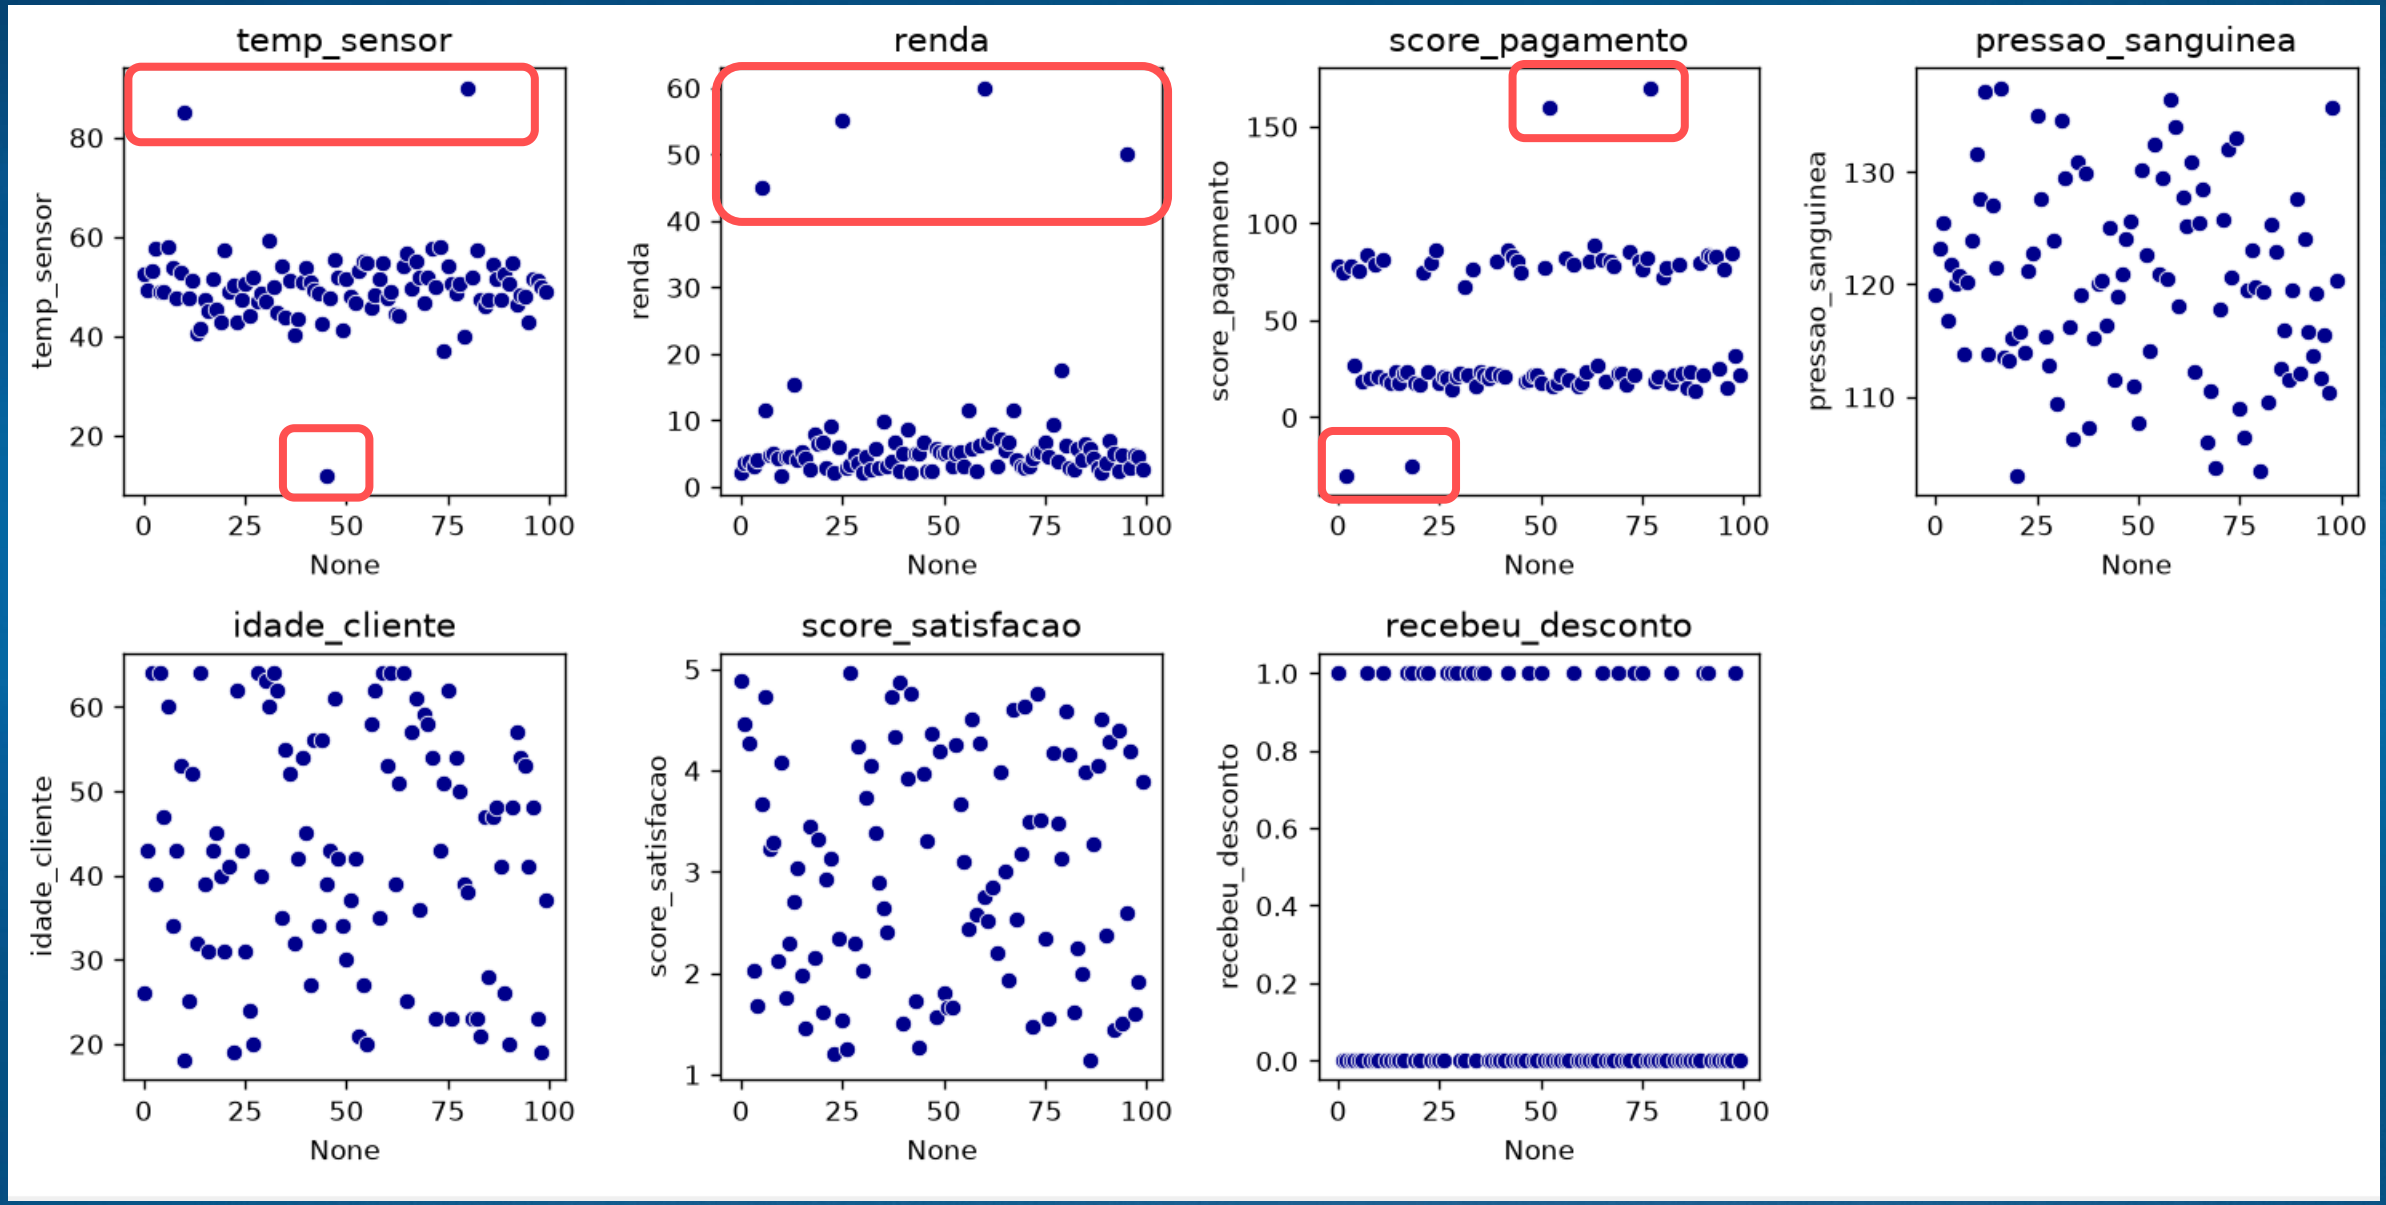
- Excluir: É a maneira mais comum de lidar com valores discrepantes quando eles representam apenas uma pequena porcentagem do conjunto de dados.
- Winsorização: Isso envolve substituir os valores extremos para limitar o efeito de outliers. Por exemplo, a winsorização de 90% atribuiria a todos os dados abaixo do 5º percentil o valor do 5º percentil e aos dados acima do 95º percentil o valor do 95º percentil. [1]
- Utilize um modelo mais robusto: Isso envolve o uso de modelos que conseguem lidar com valores discrepantes de forma intrínseca. Por exemplo, usar o RANSAC para regressão.
- Transformar os dados: Isso envolve aplicar logaritmo, raiz quadrada, etc., aos dados se os valores discrepantes forem legítimos, mas distorcerem a distribuição.
- Imputar um novo valor: Isso envolve substituir os valores discrepantes por um valor que seja representativo do restante dos dados. Por exemplo, substituir os valores discrepantes pela mediana dos dados.

https://levelup.gitconnected.com/demystifying-machine-learning-challenges-outliers-34aa4f45a1b9

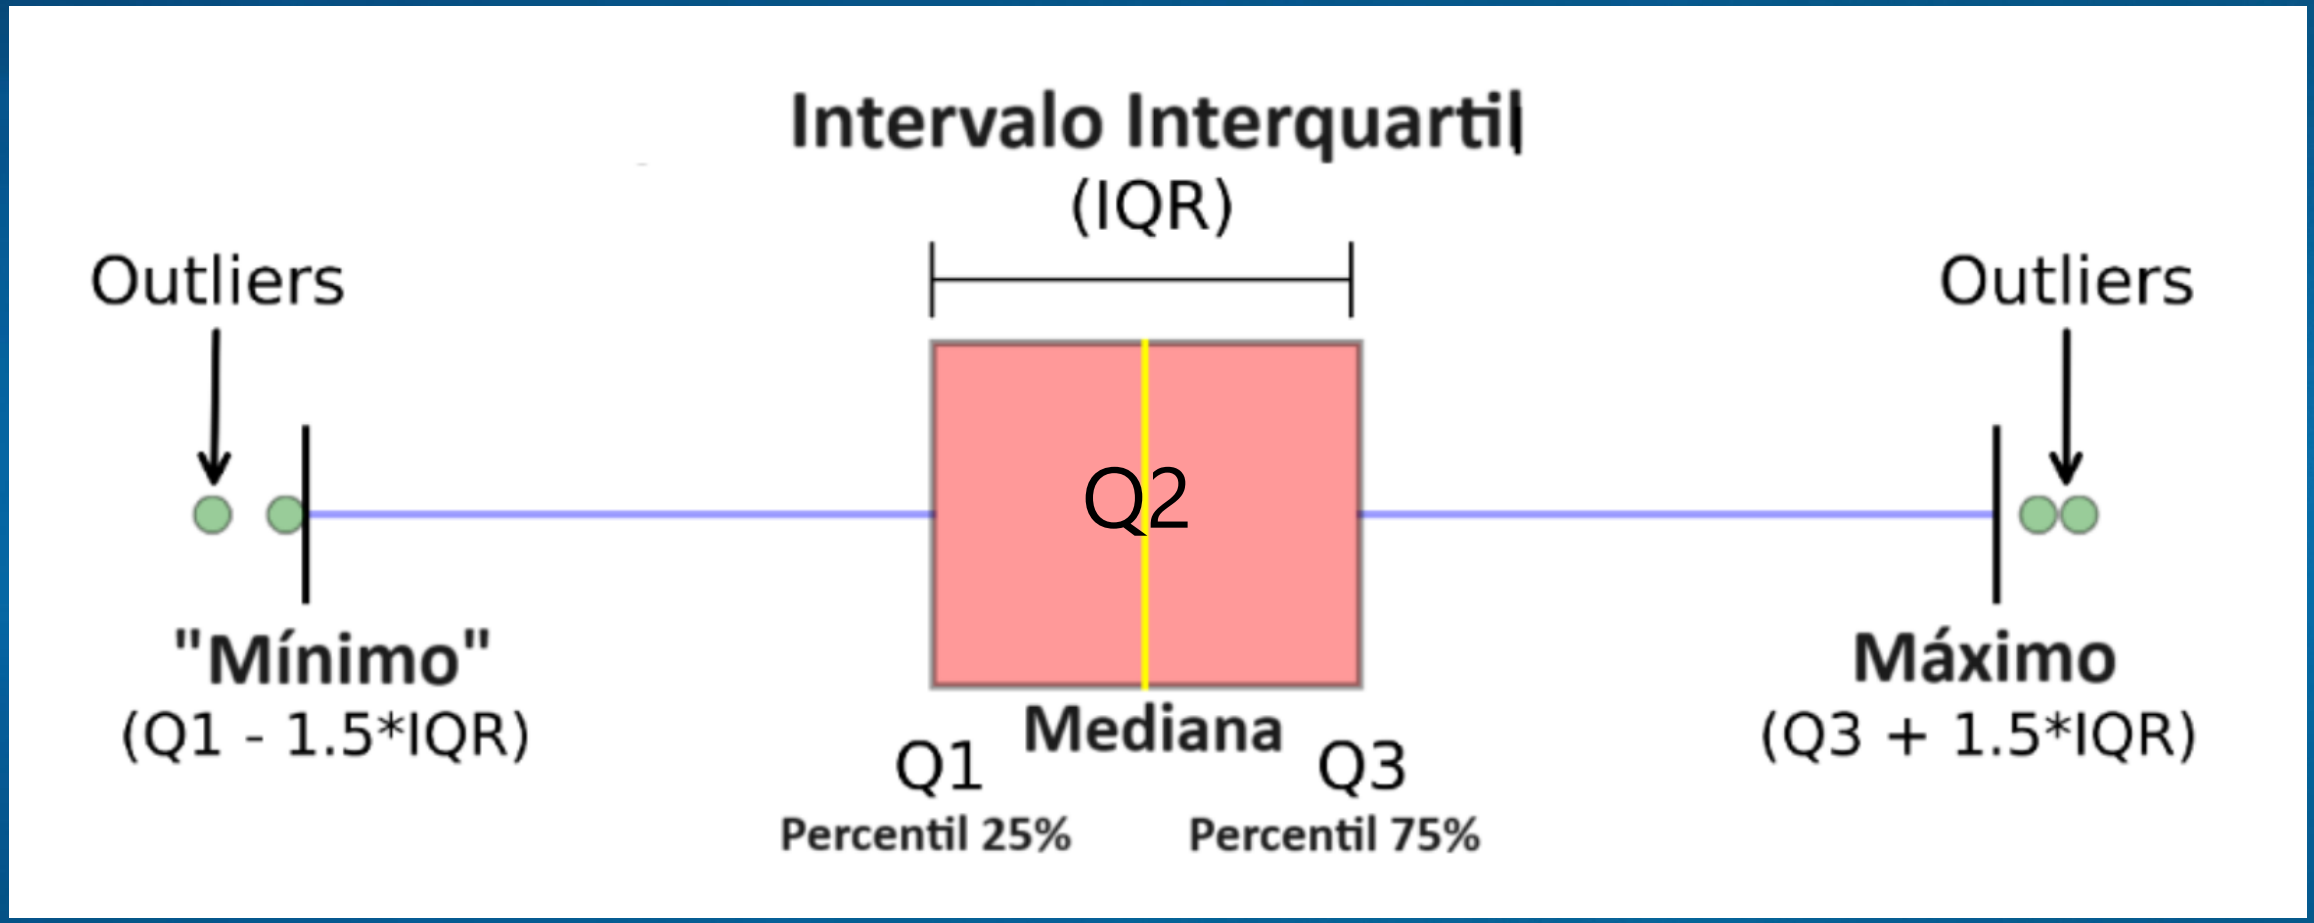
Kdeplot: Curva de distribuição contínua



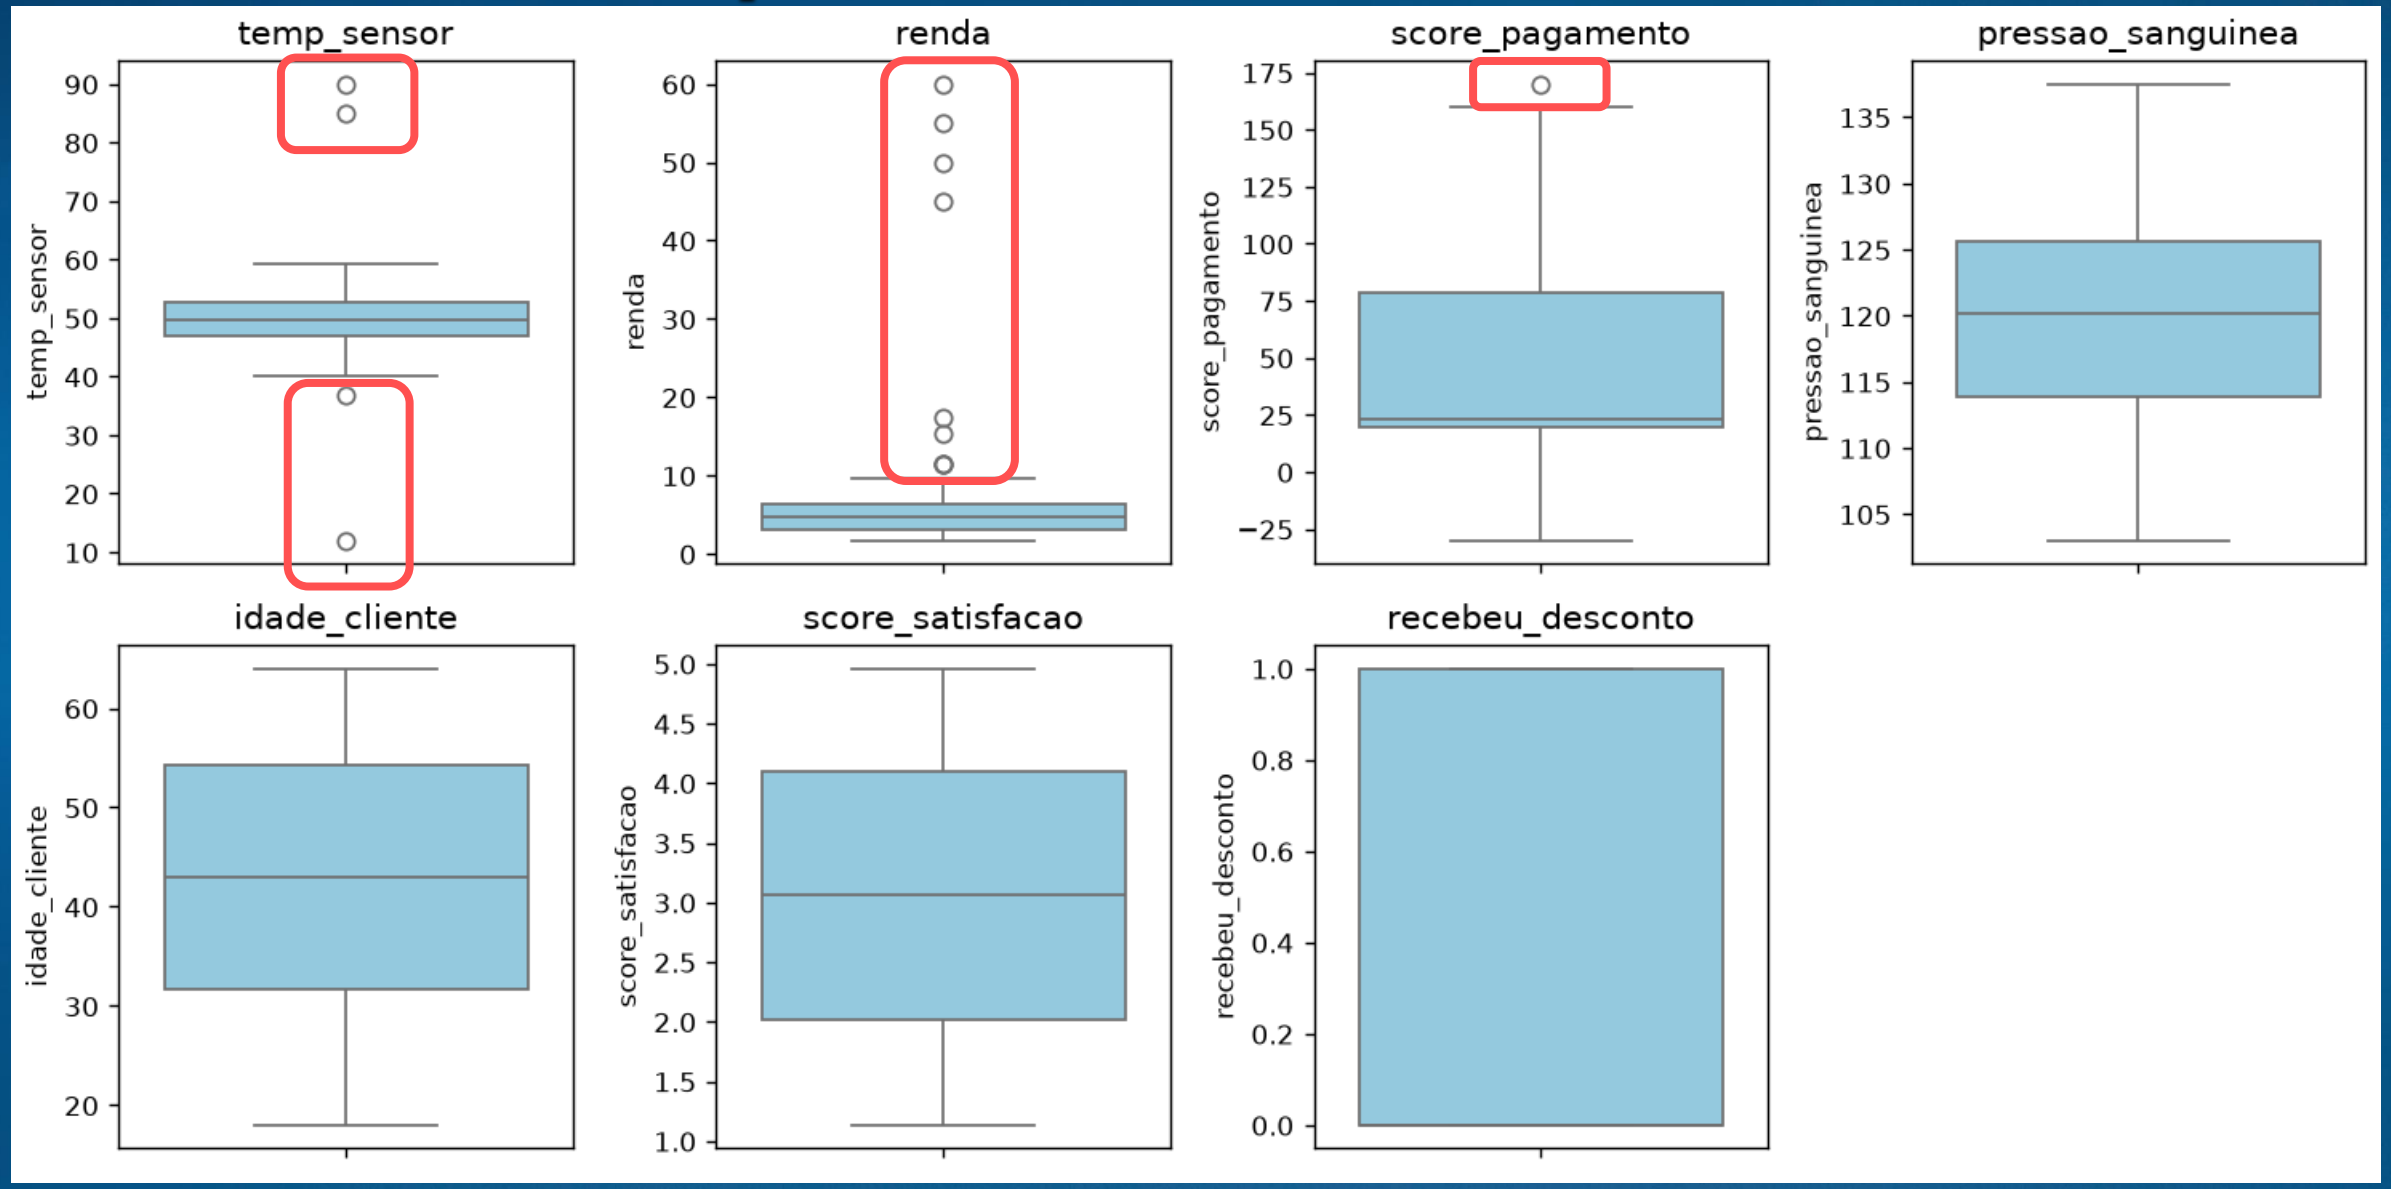
Scatterplot: Dispersão



BoxPlot


Intervalo Interquartil
(IQR)
Outliers
Outliers
Q2
"Mínimo"
(Q1 - 1.5*IQR)
Mediana
Q1
Q3
Máximo
(Q3 + 1.5*IQR)
Percentil 25%
Percentil 75%

BoxPlot: quartis, mediana e outliers

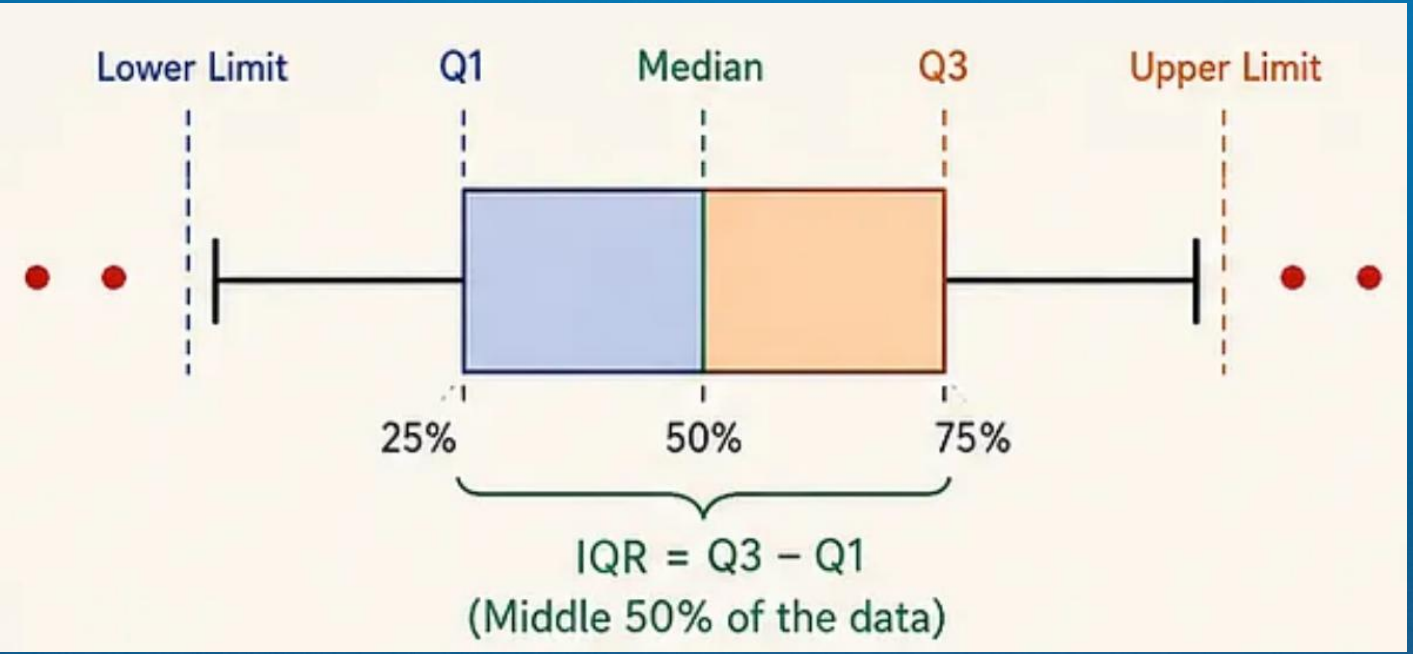


Entendendo os Quartis

Exemplo:

- Tem-se um conjunto de notas dos exames de 100 alunos.

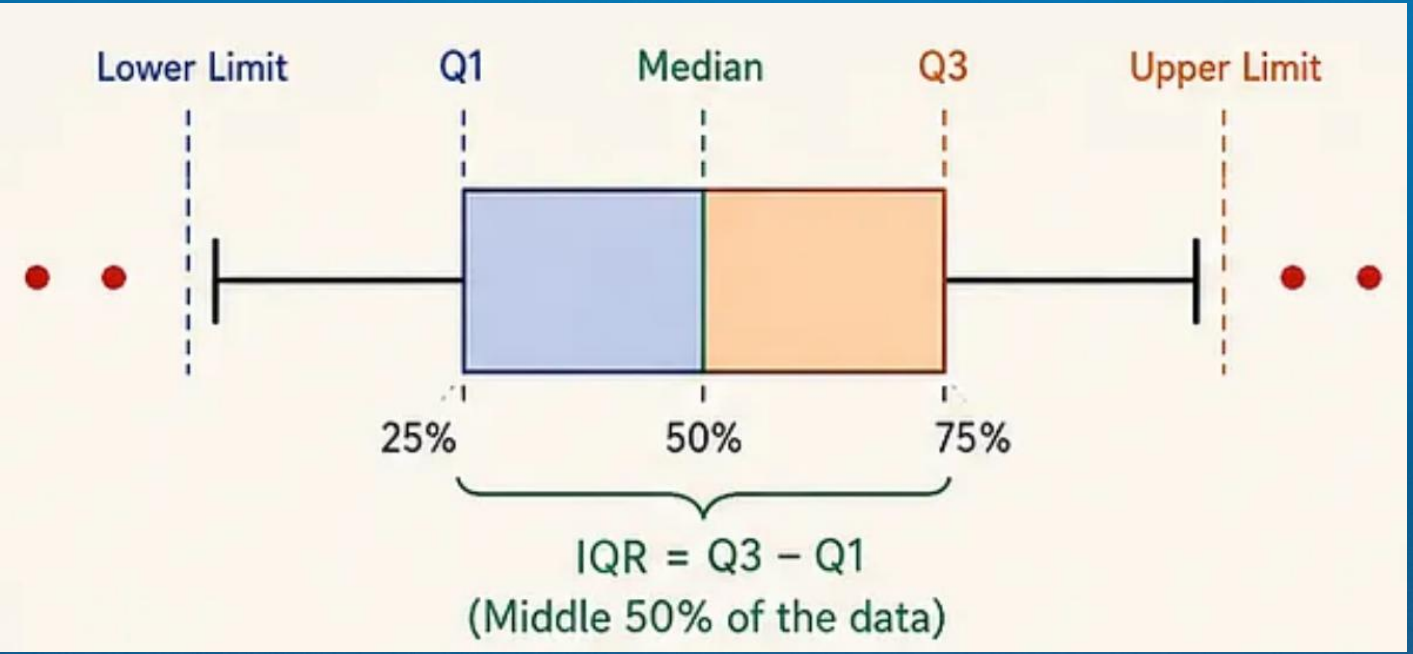
- Ordena-se as notas da menor para a maior e divide o conjunto em quatro partes iguais



Entendendo os Quartis

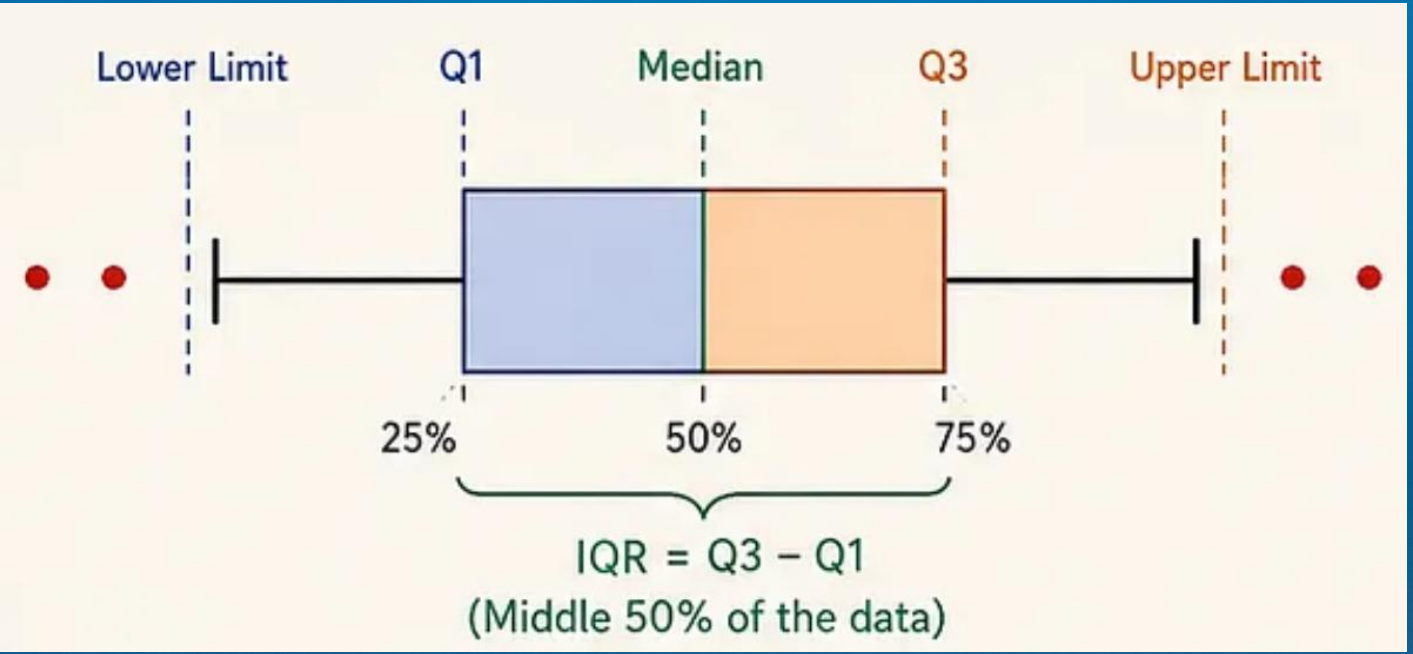
As quatro divisões são chamadas de quartis:

- **Q1 (1º Quartil)** → 25% das observações estão abaixo deste valor.
- **Q2 (2º Quartil)** → A mediana do conjunto de dados.
- **Q3 (3º Quartil)** → 75% das observações estão abaixo deste valor.



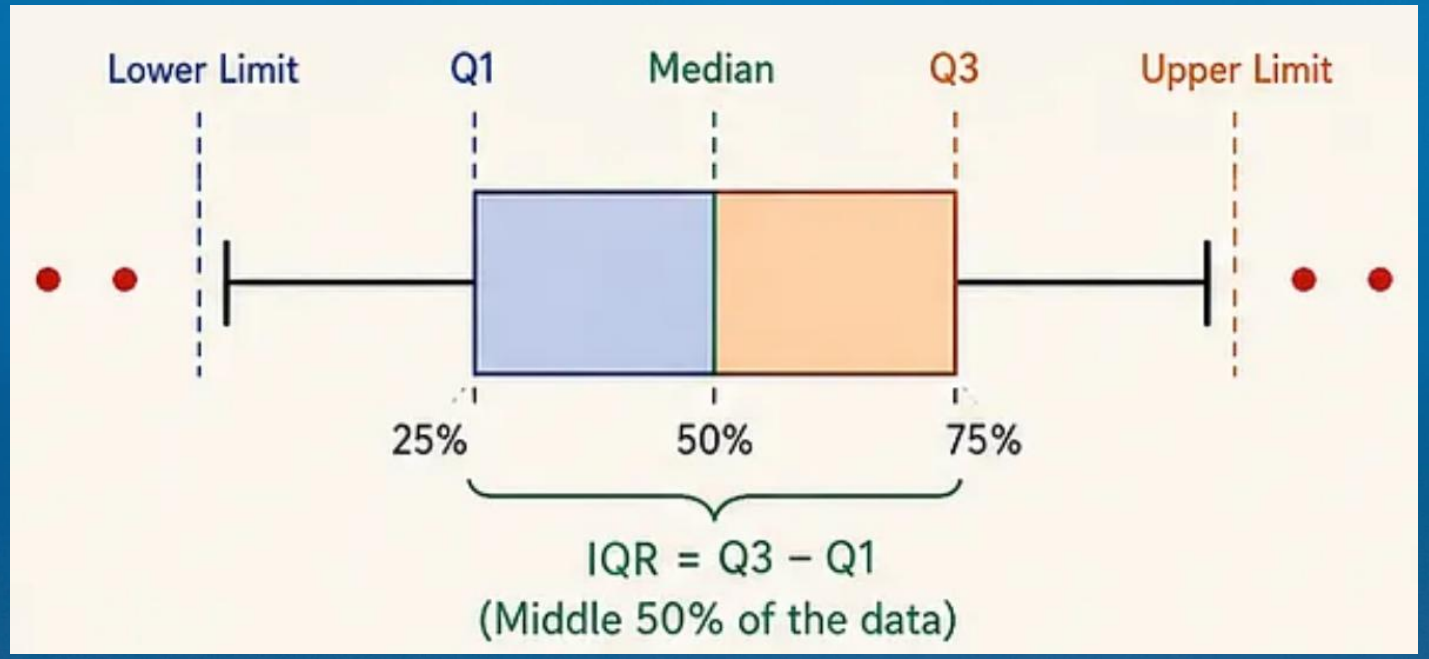
Entendendo os Quartis

- **Intervalo Interquartil (IQR)** ➔ Dispersão da região entre Q1 e Q3.
- A região entre Q1 e Q3 contém a metade central do conjunto de dados .
- Região onde a maioria das observações "normais" geralmente se encontra.



Fórmula Intervalo Interquartil (IQR)

- **IQR** = Q3 – Q1



A regra de 1,5 × IQR

- **Limite Inferior** = Q1 − 1,5 × IQR
- **Limite Superior** = Q3 + 1,5 × IQR

- Qualquer observação que se enquadre em:
  - Abaixo do limite inferior , ou
  - Acima do limite superior

- é considerado um possível Outlier.

Como lidar com Outliers?

- Análisar minuciosa dos dados.
- Compreender a causa e a natureza dos valores discrepantes antes de decidir sobre a estratégia de tratamento.
- Lidar com outliers requer conhecimento da área e análise exploratória de dados.

Como lidar com Outliers?

Remoção:

- Eliminar dados discrepantes. Pode comprometer a quantidade total de dados.

Transformação:

- Aplica-se padronização, normalização ou logaritmo.

Winsorização:

- Substituir outliers pelo valor não discrepante mais próximo.

Substituição:

- Substituir outliers por média, mediana ou a moda.

Código

```python
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns

#============================================================
#                    L E I T U R A
#============================================================
# Carregando dados
# df = pd.read_csv("Dados/10 - tabela-outliers-Max.csv")
df = pd.read_csv("Dados/11 - tabela-outliers-Min.csv")

#============================================================
#                   INSPEÇÃO GERAL
#============================================================
# print("\nTamanho do Dataset (Linhas, Colunas):")
print(df.shape)

print("\n\nTipo das colunas/variáveis:")
print(df.dtypes)

print("\nSeleção linhas:")
print(df.head(10))

print("\nResumo Estatístico (Média, Mín, Máx...):")
print(df.describe())
```

Código

```
plt.figure(figsize=(12, 6))

# --- LINHA 1 ---
# 1: Grid com 2 linha.
# 3: Grid com 4 colunas.
# 1: Seleciona o 1º espaço
plt.subplot(2, 4, 1)
sns.boxplot(y=df['temp_sensor'], color='skyblue')
plt.title('Temp Sensor')

plt.subplot(2, 4, 2)
sns.boxplot(y=df['renda'], color='salmon')
plt.title('Renda')

plt.subplot(2, 4, 3)
sns.boxplot(y=df['score_pagamento'], color='lightgreen')
plt.title('Score Pagamento')

plt.subplot(2, 4, 4)
sns.boxplot(y=df['pressao_sanguinea'], color='orchid')
plt.title('Pressão Sanguinea')
```

Código

```
# --- LINHA 2 ---
plt.subplot(2, 4, 5)
sns.boxplot(y=df['idade_cliente'], color='gold')
plt.title('Idade Cliente')

plt.subplot(2, 4, 6)
sns.boxplot(y=df['score_satisfacao'], color='coral')
plt.title('Score Satisfação')

plt.subplot(2, 4, 7)
sns.boxplot(y=df['recebeu_desconto'], color='teal')
plt.title('Recebeu Desconto')

plt.tight_layout()
plt.show()
```

Código

```
# Obtêm as colunas numéricas
colunas_numericas = df.select_dtypes(include=['int64', 'float64']).columns.tolist()

# Cria a figura e a grade de eixos (2 linhas x 4 colunas)
fig, ax = plt.subplots(2, 4, figsize=(12, 6))

# Transforma a Matriz em Vetor de 8 posições ([ax1, ax2, ..., ax8])
axes_achatados = ax.flatten()

# Desenha os gráficos
for i, nome_col in enumerate(colunas_numericas):
    axes_achatados[i].set_title(nome_col)

    #-----------------------------------------------------
    # BoxPlot: Estatística (quartis, mediana e outliers)
    #sns.boxplot(y=df[nome_col], color='skyblue', ax=axes_achatados[i])

    #-----------------------------------------------------
    # kdeplot = Curva de distribuição contínua
    sns.kdeplot(x=df[nome_col], color='darkblue', ax=axes_achatados[i], fill=True)

    #-----------------------------------------------------
    # Scatterplot: Dispersão
    # sns.scatterplot(x=df.index, y=df[nome_col], color='darkblue', ax=axes_achatados[i])
```

Código

```
# Remove os quadros/eixos em branco que sobraram no grid
for j in range(len(colunas_numericas), len(axes_achatados)):
    fig.delaxes(axes_achatados[j])

plt.tight_layout()
plt.show()
```

Código

```
#=========================================================
#                  MÉTODOS ESTÁTISTICO
#=========================================================
# Obtêm as colunas numéricas
colunas_numericas = df.select_dtypes(include=['int64', 'float64']).columns.tolist()


print("\n\nAntes:\n")
print(df.head())
print("\n\n\n")
```

Código

```
for i, nome_col in enumerate(colunas_numericas):
    Q1 = df[nome_col].quantile(0.25)
    Q2 = df[nome_col].quantile(0.5)
    Q3 = df[nome_col].quantile(0.75)

    IQR = Q3 - Q1

    valor_min = Q1 - 1.5 * IQR
    valor_max = Q3 + 1.5 * IQR

    # Filtra as linhas que possuem valores fora dos limites
    outliers = df[(df[nome_col] < valor_min) | (df[nome_col] > valor_max)]
    qtd_outliers = len(outliers)

    # Imprime o resultado para cada coluna
    if qtd_outliers > 0:
        print(f"A coluna '{nome_col}' POSSUI {qtd_outliers} outlier(s).")
        print(f"\tMin: {valor_min} \tMax: {valor_max}")
    else:
        print(f"A coluna '{nome_col}' NÃO possui outliers.")

    # Se houver outliers, então substitui pelo valor MIN
    # caso contrário, substitui pelo próprio valor da coluna
    df[nome_col] = np.where(df[nome_col] < valor_min, valor_min, df[nome_col])

    # Se houver outliers, então substitui pelo valor MAX
    # caso contrário, substitui pelo próprio valor da coluna
    df[nome_col] = np.where(df[nome_col] > valor_max, valor_max, df[nome_col])
```

F I M

“Nossa história, depositada nas mãos de Deus, pode ser reescrita a qualquer momento.”

— PE. LUÍS ERLIN (9 MESES COM MARIA)

Prof. Dr. Ricardo Luis Balieiro
ricbalieiro@gmail.com