Avaliação Prática Integrada P2

1. Contextualização do Projeto

Você foi contratado como cientista de dados por uma *fintech*/plataforma de precificação e concessão de financiamento de **veículos seminovos e usados**. A empresa possui dados históricos de clientes, especificações técnicas de veículos e valores de avaliação para compra/venda. No entanto, o banco de dados atual apresenta diversos problemas operacionais de ingestão e falhas de telemetria.

Sua missão é desenvolver um **Pipeline Completo de Machine Learning**, abrangendo desde o diagnóstico e tratamento na Análise Exploratória de Dados (EDA) até o treinamento e exportação de um modelo preditivo de regressão simples, integrado a uma aplicação web interativa em Flask.

2. Estrutura dos Dados (Datasets do Projeto)

Dataset 1: clientes_veiculos.csv (Base Principal de Treino/EDA)

- id_cliente: Identificador único do cliente (int / str).
- cpf_cliente: CPF do proponente (str).
- idade_cliente: Idade do proponente em anos (int / float).
- renda_mensal: Renda bruta declarada em R$ (float).
- potencia_cv: **Característica Principal (X)** - Potência do motor do veículo em Cavalos de Potência (float).
- ano_fabricacao: Ano de fabricação do veículo (int).
- score_credito: Score de crédito interno de 0 a 1000 (float).
- data_solicitacao: Data de cadastro do pedido (str / datetime).
- valor_avaliado_brt: **Variável Alvo (Target - y)** - Valor estimado de mercado do veículo em R$ (float).

Dataset 2: telemetria_consultas.csv (Série Temporal / Registros de Sensores de Acesso)

- data_hora: Carimbo de data e hora (str).
- requisicoes_minuto: Quantidade de requisições por minuto no servidor (float).

3. Requisitos do Projeto Avaliativo

O projeto deverá está estruturado nas **4 Etapas** descritas a seguir.

Etapa 1: Análise Exploratória & Limpeza de Dados (EDA)

1. **Diagnóstico e Imputação de Valores Ausentes:**
    - Calcule o total e a porcentagem de valores nulos em cada coluna.
    - Aplique as regras de decisão para tratamento de ausentes:
        - Remova linhas onde a chave única (cpf_cliente ou id_cliente) seja nula.
          (Efetuar Print da tela: Projeto, Arquivo e Terminal)
        - Se houver coluna com mais de 50% de dados ausentes, remova a coluna.
          (Efetuar Print da tela: Projeto, Arquivo e Terminal)
        - Para variáveis numéricas contínuas com distribuição simétrica/normal (|skew| ≤ 0.5), impute os nulos com a **Média**.
          (Efetuar Print da tela: Projeto, Arquivo e Terminal)
        - Para variáveis com distribuição assimétrica (|skew| > 0.5) ou presença de outliers, impute os nulos com a **Mediana**.
          (Efetuar Print da tela: Projeto, Arquivo e Terminal)
    - No dataframe de telemetria/série temporal, aplique **Forward Fill (ffill)**, **Backward Fill (bfill)** ou **Interpolação Linear (interpolate())** conforme a melhor lógica observada.
      (Efetuar Print da tela: Projeto, Arquivo e Terminal)

2. **Tratamento de Registros Duplicados:**
    - Identifique e remova duplicatas exatas.
      (Efetuar Print da tela: Projeto, Arquivo e Terminal)
    - Identifique duplicatas parciais com base no cpf_cliente. Converta data_solicitacao para o tipo datetime, ordene a base de forma ascendente por CPF e data, remova as duplicatas parciais mantendo apenas a última ocorrência cadastrada para evitar vazamento de dados (*Data Leakage*).
      (Efetuar Print da tela: Projeto, Arquivo e Terminal)

3. **Detecção e Tratamento de Outliers (Valores Discrepantes):**
    - Gere Boxplots e Kdeplots visuais para analisar a distribuição das variáveis numéricas.
      (Efetuar Print da tela: Projeto, Arquivo e Terminal)
      (Efetuar Print dos gráficos)
    - Implemente o método estatístico da Regra do Intervalo Interquartil (**1.5 x IQR**):

IQR = Q3 - Q1

Limite Inferior = Q1 - 1.5 x IQR

Limite Superior = Q3 + 1.5 x IQR
(Efetuar Print da tela: Projeto, Arquivo e Terminal)

- Aplique a técnica de **Capping (Winsorização)** para limitar os outliers nos valores extremos (inferior e superior) sem eliminar os registros da base.
  (Efetuar Print da tela: Projeto, Arquivo e Terminal)

Etapa 2: Divisão da Amostra & Treinamento de Modelos (Univariado)

1. **Separação de Features e Target (Apenas 1 Feature em X):**
   - Defina a matriz de características X contendo múltiplas variáveis explicativas relevantes para a precificação do veículo (ex.: potencia_cv, ano_fabricacao e score_credito).
     (Efetuar Print da tela: Projeto, Arquivo e Terminal)
   - Defina o vetor alvo y contendo a variável contínua a ser prevista (**valor_avaliado_brt**).
     (Efetuar Print da tela: Projeto, Arquivo e Terminal)

2. **Divisão de Treino e Teste:**
   - Separe o conjunto de dados na proporção de **70% para Treino** e **30% para Teste**, garantindo reprodutibilidade utilizando.
     (Efetuar Print da tela: Projeto, Arquivo e Terminal)

3. **Treinamento e Comparação de Algoritmos Preditivos:** Treine os modelos de regressão aprendidos utilizando a mesma feature X:
   - **Modelo A:** Regressão Linear Simples (LinearRegression).
     (Efetuar Print da tela: Projeto, Arquivo e Terminal)

Etapa 3: Exportação do Modelo com Joblib

1. Salve o modelo treinado em um chamado **modelo_veiculo.pkl** no diretório Modelos.
   (Efetuar Print da tela: Projeto, Arquivo e Terminal)

Etapa 4: Integração com Aplicação Web em Flask

Crie uma estrutura básica de projeto web em Flask para permitir simulações em tempo real.

1. **app.py (Script Flask):**
   - Carregue o modelo **modelo_veiculo.pkl** na inicialização da aplicação.
     (Efetuar Print da tela: Projeto, Arquivo e Terminal)

- Rota / (GET): Renderiza o formulário **index.html**.
  (Efetuar Print da tela: Projeto, Arquivo e Terminal)

- Rota /resultado (POST): Recebe a potência informada (potencia_cv), e realiza a previsão e envia o resultado formatado em R$ para a página **resultado.html**.
  (Efetuar Print da tela: Projeto, Arquivo e Terminal)

2. **Templates HTML (/templates):**
   - **index.html:** Formulário contendo o campo numérico para a **Potência (CV)** e o botão de envio.
     (Efetuar Print da página renderizada no navegador)
   - **resultado.html:** Exibição clara e formatada do valor estimado do veículo com botão de retorno à página inicial.
     (Efetuar Print da página renderizada no navegador)

4. Critérios de Avaliação

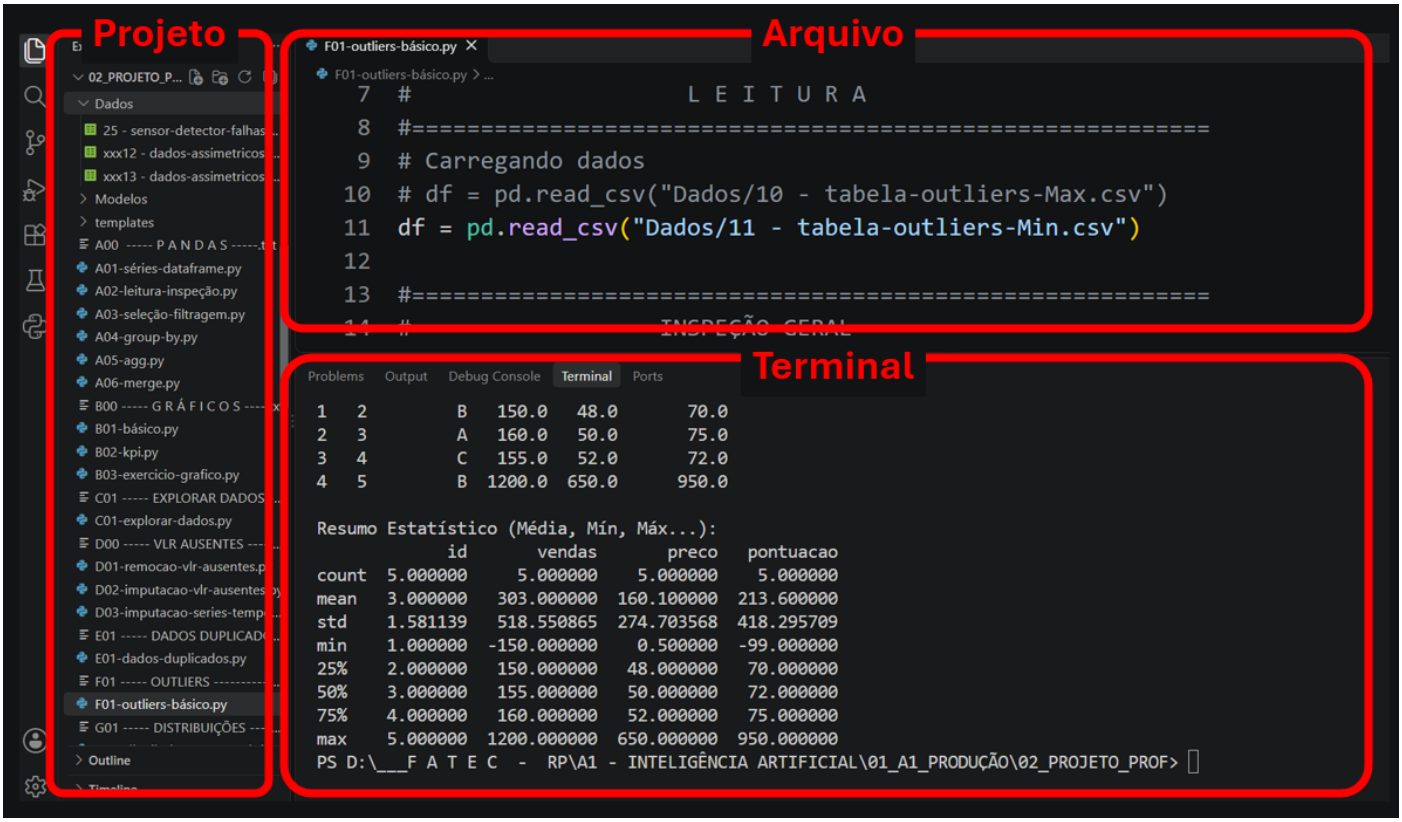
ITEM	PONTUAÇÃO
1. Tratamento EDA	1 ponto
2. Duplicatas & Outliers	1 ponto
3. Modelagem ML	1 ponto
4. Deploy Flask	3 pontos
Total	**6 pontos**

5. Diretrizes de Entrega

A entrega deve ser estruturada em dois componentes principais:

6.1. Relatório Acadêmico (PDF)

- **Capa Padrão:** Nome da instituição, disciplina, título do trabalho, **nome(s) do(s) integrante(s) (conforme lista de chamada. Trabalhos sem nomes ou nomes incompletos ou parciais correm o risco de não ter a nota lançada)** e data.
- **Evidências Visuais (Screenshots):**
  - **Seção 1.2:** ***Prints* legíveis divididos** exibindo: **Projeto, Arquivo e Terminal** conforme o exemplo da figura abaixo. **FERRAMENTA OFICIAL VS CODE. NÃO SERÃO ACEITOS CÓDIGOS DESENVOLVIDOS EM OUTRAS IDES**



3.2. Pacote de Scripts (.py)

- Envio dos códigos-fonte original (.py) utilizados no projeto

3. 4. Instruções para Entrega e Validação da Avaliação

1. **Formatação e Nomeação do Arquivo:**
    - **Zipar TODOS os arquivos. NÃO SERÃO** aceitos arquivos que não estejam zipados.
    - Escolher um dos integrantes e nomear o arquivo com seu nome no padrão: **<T1 ou P1 ou T2 ou P2>_Nome-Sobrenome.zip**
      (Ex.: T2_ MariaDeJesus.zip).
    - Postar **apenas no perfil do aluno** com o nome no arquivo.
    - Arquivos fora **do padrão de nomenclatura** ou que **não contenham todos os documentos** solicitados no .zip estarão sujeitos a **desconto na nota final**.
    - Certifique-se de que o arquivo enviado esteja íntegro e legível. **Arquivos corrompidos ou em branco não serão considerados para correção**.
2. **Identificação dos Integrantes:**
    - Os nomes constantes na avaliação devem corresponder **exatamente ao da lista de chamada**. Divergências de identificação poderão resultar no **NÃO LANÇAMENTO DA NOTA**.

3. **Prazo e Local de Envio:**
    - **Plataforma Oficial:** Só serão aceitos trabalhos postados/anexados diretamente na plataforma informada pelo professor. **Não serão aceitos trabalhos ou links externos hospedados em repositórios ou drives como GitHub, OneDrive, Google Drive, etc.**
    - **Não serão aceitas** entregas fora do prazo estabelecido **nem enviadas por canais distintos** do ambiente oficial indicado para a disciplina.

4. **Autenticidade e Integridade Acadêmica:**
    - **Conformidade com o Conteúdo Ministrado:** Soluções que empreguem métodos, funções avançadas ou padrões totalmente divergentes do programa da disciplina — sugerindo cópia de fontes externas ou auxílio não autorizado — serão desconsideradas (receberão nota **zero** (**0,0**)).
    - **Uso de IA:** Avaliações que apresentem **indícios de geração por ferramentas de Inteligência Artificial** receberão nota **zero** (**0,0**).
    - **Plágio:** Trabalhos idênticos aos de outros estudantes ou com trechos copiados de outras avaliações serão integralmente anulados, receberão nota **zero** (**0,0**).

4. Modalidades de Entrega e Pontuação

- **Trabalho em Dupla ou individual (Valor: 6,0 pontos):**